项目1 — 时序数据预测（助教：肖子洋）

问题定义

- ✓ 给定一个零售商平台的历史一段时间的销售数据（包括商品日期、商店、商品内容、促销信息、数量等），要求预测未来某个时间点单位商品的销售额。

数据集

- ✓ 下载地址：https://www.kaggle.com/c/store-sales-time-series-forecasting/data
- ✓ 数据说明：
  - 训练集 train.csv，包含了商品销售的一系列特征（如商品类型、销量等）
  - 测试集 test.csv，包含特征跟训练集一样，其中sales字段是模型的预测目标
  - 另外，还有 stores.csv（商店信息）、oil.csv（每日油价，这个商店是厄瓜多尔的一个线上零售店，商品价格跟油价强相关）、holidays_events.csv（节假日信息，会影响商品交易量）

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目1 — 时序数据预测（助教：肖子洋）

评价指标

用RMSLE（Root Mean Squared Logarithmic Error）来评估模型的效果：

$$\sqrt{\frac{1}{n}\sum_{i=0}^{n}(\log(1+\hat{y}_i)-\log(1+y_i))^2}$$

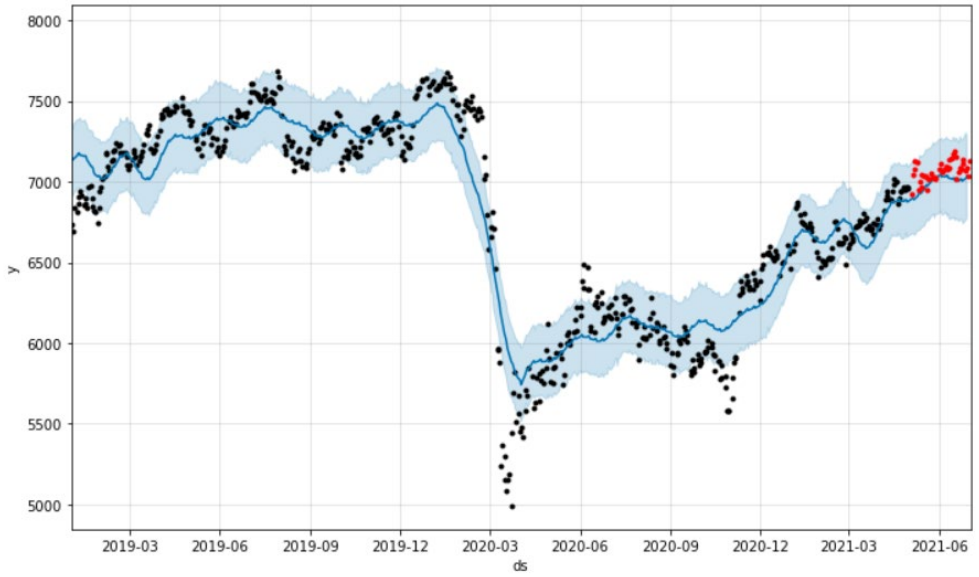
- 其中:
- n 是样例的总数
- $\hat{y}_i$ 是模型预测的销售量
- y_i 是真实销售量
- RMSLE 的值越小越好

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目1 — 时序数据预测（助教：肖子洋）

Baseline算法

Prophet算法：一种开源的时间序列预测算法，将时间序列拆分为趋势项、周期项和事件项，能够快速且准确地预测未来时间序列数据。



数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目1 — 时序数据预测（助教：肖子洋）

参考文献和代码

- 基于深度学习的时间序列模型（https://www.kaggle.com/code/dimitreoliveira/deep-learning-for-time-series-forecasting）
- 经典的时间序列预测算法汇总（https://www.kaggle.com/competitions/store-sales-time-series-forecasting/discussion/276912）
- ARIMA算法的Python实现（https://github.com/krishnaik06/ARIMA-And-Seasonal-ARIMA）
- Facebook Prophet官方文档（https://facebook.github.io/prophet/docs/quick_start.html）
- Neural Prophet教程（https://ai.facebook.com/blog/neuralprophet-the-neural-evolution-of-facebooks-prophet/）

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目2 — 基于大模型的合同审阅（助教：谢京容）

问题背景

- ✓ 传统合同审阅依赖人工逐条核查，耗时耗力且易因专业知识不足导致法律风险。近年来，大模型技术在自然语言处理领域的突破为自动化合同审阅提供了新思路，通过智能风险预测和条款合规性检查，可大幅提升审阅效率。

问题定义

- ✓ 给定一份待审阅合同、风险审查清单和专家知识库，调用大语言模型，根据审查清单给出的检查点和专家知识库的参考意见，筛选出含有风险的合同条款，准确高效地实现风险条款的识别。

数据集： 链接: https://pan.baidu.com/s/1TzX-Aj2y9vLUhil_r1eaQw 提取码: 5fd5

- ✓ 数据说明:
  - 待审阅合同(contract.csv)：已分割好的合同条款，包含一级标题和条款
  - 风险审查清单(checklist.csv)：包含检查点和常见表现形式
  - 专家知识库(clause_review_pair.csv)：条款-评审对，包含检查点、案例条款和专家对条款的评价
  - Ground Truth(GT_contract_risk.csv):风险条款参考结果，其中A表示条款有风险，B表示无风险

数据智能实验室 DATA INTELLIGENCE LABORATORY
DI-LAB
浙江大学 Zhejiang University

项目2 — 基于大模型的合同审阅（助教：谢京容）

评测指标

用F1值（F1-Score）综合评估模型对风险合同的识别能力，F1值越大越好。

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- 精确率（Precision）：预测为正类的样本中，真实为正类的比例。

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

- 召回率（Recall）：真实为正类的样本中，被正确预测为正类的比例。

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

符号解释:

TP（True Positive）：模型正确识别的风险样本数量。

FP（False Positive）：模型误判为风险的非风险样本数量。

FN（False Negative）：模型漏判的真实风险样本数量。

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目2 — 基于大模型的合同审阅（助教：谢京容）

参考文献

- Wong, S., Zheng, C., Su, X., & Tang, Y. (2024). Construction contract risk identification based on knowledge-augmented language models. Computers in Industry, 157-158, 104082.（http://arxiv.org/abs/2309.12626）
- RAG应用参考（https://python.langchain.com/docs/tutorials/rag/）
- DeepSeek API官方文档（https://api-docs.deepseek.com/zh-cn/）
- 通义千问 API官方文档（https://bailian.console.aliyun.com/?tab=api#/api）

项目3 — 视频帧查询过滤器（助教：张柏岩）

问题定义

- ✓ 给定一个原始视频以及查询目标图片，如何设计一个二分类过滤器，快速并且准确地筛除不包含对象的视频帧
- ✓ 每个查询对应一个目标对象的图片，并且事先已经标注好包含该目标对象的视频帧集合**G**
- ✓ 二分类过滤器将作用于所有视频帧，最后返回未被排除的视频帧集合**P**

数据集：https://pan.baidu.com/s/1SO_dj1fV00DR3MJECOB2zQ?pwd=4rcq 提取码：4rcq

- ✓ 测试视频为test.mp4，时长20分钟
- ✓ 10个查询目标图像，以及每个查询对象在视频出现中的视频帧区间
- ✓ 每个查询的视频帧区间从文件名获取，例如”9_14198~14579.jpg”表示9号车辆出现的区间是[14198, 14579]

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目3 —视频帧查询过滤器（助教：张柏岩）

- **Baseline算法 【下载链接：https://github.com/China-zby/filter.git】**
  - ✓ 思想一：由于摄像头位置固定，背景信息固定，利用前景快速提取抽离出画面中移动的车辆（比直接使用深度学习的目标检测器更快）
  - ✓ 思想二：使用颜色信息作为查询目标的过滤器指标，将查询对象的颜色信息与每帧抽取出来的目标对象的整体颜色信息作比较，设置相似性阈值，如果没有出现跟查询对象颜色相近的物体，则过滤该视频帧
- **实现细节：MOG前景提取模型+opencv库提供的颜色直方图提取函数，通过计算查询图像与每帧的颜色直方图相似度决定过滤与否**
- **同学们可以使用更新的前景提取技术，鲁棒性更好的相似度衡量方法，或者引用其他视觉特征（如纹理等）来设计性能更好的过滤器**

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University

项目3 —视频帧查询过滤器（助教：张柏岩）

评测指标

- ✓ 算法运行时间：对于每个查询，计算过滤器跑完所有视频帧的平均运行时间（由于不同个人电脑的差异，最后助教会统一在服务器上重新运行，确保对比公平）
- ✓ 算法过滤效果：用F1-score指标，其中precision的计算方式是$\frac{P \cap G}{|P|}$，recall的计算方式是$Recall = \frac{P \cap G}{|G|}$，
- ✓ recall要求不低于0.7

数据智能实验室 DATA INTELLIGENCE LABORATORY
DI-LAB
浙江大学 Zhejiang University

Project提交内容清单

- 项目代码
- 实验报告（标题注明哪个项目），包括以下3个部分即可
  - ✓ **贡献总结**：概括总结贡献
  - ✓ **技术方案**：介绍解决问题所使用的技术方案和实现细节
  - ✓ **实验分析**：介绍实验结果和相应的结果分析
- 答辩PPT
- 评分标准
  - ✓ **算法效果、投入精力、方法原创性、Presentation 、实验报告**

数据智能实验室 DATA INTELLIGENCE LABORATORY
浙江大学 Zhejiang University